

Predlog projekta

Dušica Pešić sv46/2022
Darinka Lončar sv31/2022

Naziv teme

Sistem za personalizovane preporuke knjiga

Opis projekta

U okviru ovog projekta planiramo da razvijemo **hibridni sistem preporuka knjiga** zasnovan na **Neural Collaborative Filtering (NCF)**. Sistem korisnicima predlaže knjige koje bi im se verovatno svidеле, koristeći kombinaciju prethodnih ocena korisnika i dodatnih informacija o knjigama i korisnicima.

Za razliku od klasičnog kolaborativnog filtriranja, ovaj model uključuje **side features knjiga** (autor, godina izdanja, izdavač) i **side feature korisnika** (starost), čime omogućava bolje predikcije, uključujući i **novim korisnicima**. Na taj način, korisnici mogu otkriti knjige koje možda ne bi sami pronašli, a sistem može davati preporuke čak i kada nema dovoljno istorijskih ocena, čime se efikasno prevazilazi **cold-start problem** za nove korisnike.

Motivacija

S obzirom na veliki broj knjiga koje su danas dostupne, korisnici često imaju poteškoće u izboru šta sledeće da čitaju. Zato želimo da napravimo sistem koji personalizuje korisničko iskustvo i pomaže im da lakše pronađu knjige koje odgovaraju njihovom ukusu. Ovaj projekat nam pruža priliku da spojimo teorijsko znanje sa praktičnim problemom koji ima primenu u svakodnevici.

Skup podataka

Koristićemo **Book-Crossing dataset**, koji sadrži više od milion ocena koje su korisnici dali različitim knjigama. Pored ocena, dataset uključuje osnovne informacije o knjigama kao što su naslov, autor, godina izdanja i izdavač; i dodatnu informaciju o starosti korisnika. Ocene sa vrednošću nula neće biti uključene u obradu jer ne pružaju korisne informacije. Ovo je primer rada sa **sparse matricom**, jer većina korisnika nije ocenila većinu knjiga, što je česta pojava kod sistema preporuka.

Pretprocesiranje podataka

Na početku ćemo ukloniti ocene sa vrednošću nula, kao i korisnike i knjige sa vrlo malim brojem ocena. Nakon toga ćemo formirati **korisnik-knjiga matricu**. Normalizovaćemo ocene po korisniku, kako bismo umanjile razlike u

stilovima ocenjivanja zato što neki korisnici generalno daju više ocene, dok su drugi stroži. **Korisnička starost** biće korišćena kao numerička vrednost; za korisnike koji ne unesu starost korišćemo **posebnu vrednost ili default broj**. Kategorijske karakteristike knjiga (autor, izdavač, naslov) biće pretvorene u **embeddinge**, a numeričke karakteristike knjiga (godina izdavanja) biće **normalizovane**.

Metodologija

- Primenićemo **hibridni NCF**:
 - Embedding slojevi: za user_id, book_id, autor, izdavač.
 - **Numeričke vrednosti**: starost korisnika i normalizovana godina izdanja knjige.
 - Svi embedinzi i numeričke vrednosti biće **konkatenirani** i prosleđeni kroz **MLP slojeve**.
 - Output sloj predviđa ocenu ili verovatnoću da korisnik voli knjigu.

Evaluacija

Model ćemo evaluirati pomoću **RMSE** (Root Mean Square Error) metrike kada budemo radile predikciju ocena, a za evaluaciju top n preporuka korišćemo **Precision@k** i **Recall@k**. Podatke ćemo podeliti na trening i test skup u odnosu 80/20.

Tehnologije

Projekat ćemo razvijati u Pythonu, uz korišćenje sledećih biblioteka: pandas i numpy za obradu podataka, matplotlib i seaborn za vizualizaciju, scikit-learn za osnovne modele i evaluaciju, kao i PyTorch za implementacija hibridnog NCF modela.

Literatura i izvori

- Book-Crossing dataset: <https://www.kaggle.com/datasets/arashnic/book-recommendation-dataset>
- Primeri preporuka iz prakse: <https://www.goodreads.com/>